Fase 2
Procesamiento del lenguaje
natural (NLP) para la detección de
ataques de ingeniería social





O1Correccionesde la fase 1

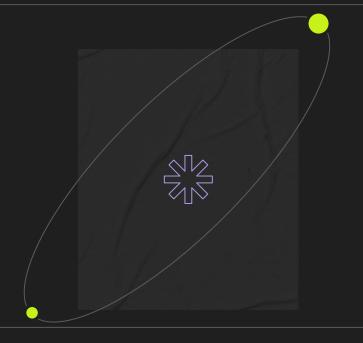


Se obtuvo un nuevo dataset, que cumple con los requerimientos planteados durante la fase 1.

https://github.com/muditmathur2020/RansomwareDetection/blob/master/Ransomware.csv



02 Modelos ML/DL/RL



Regresión Logística

Random Forest

Support Vector Machines

- Simplicidad
- Interpretabilidad
- Rápida convergencia y entrenamiento
- Menor riesgo de sobreajuste

- Robustez y precisión
- Manejo de características no lineales
- Importancia de las características

- Eficacia en espacios de alta dimensión
- Flexibilidad
- Robustez
- Generalización



O3 Analisis exploratorio

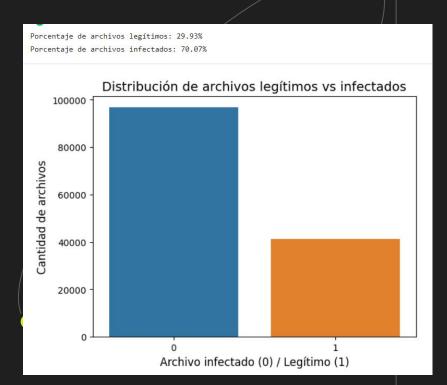
V						E 11500	
	Name object	md5 object	Machine int64	SizeOfOptional	Characteristics i	MajorLinkerVer	MinorLini
0	memtest.exe	631ea355665f28d 4707448e442fbf	332	224	258	9	
1	ose.exe	9d10f99a6712e28f 8acd5641e3a7ea	332	224	3330	9	
2	setup.exe	4d92f518527353c 0db88a70fddcfd	332	224	3330	9	
3	DW20.EXE	a41e524f8d45f007 4fd07805ff0c9b12	332	224	258	9	
4	dwtrig20.exe	c87e561258f2f865 0cef999bf643a731	332	224	258	9	
5	airappinstaller.exe	e6e5a0ab3b1a271 27c5c4a29b237d	332	224	258	9	
6	AcroBroker.exe	dd7d901720f71e7e 4f5fb13ec973d8e9	332	224	290	9	
7	AcroRd32.exe	540c61844ccd78c 121c3ef48f3a34f	332	224	290	9	
8	AcroRd32Info.exe	9afe3c62668f55b8 433cde6022582	332	224	290	9	
9	AcroTextExtractor.	ba621a96e44f655 8c08cf25b40cb1	332	224	290	9	

La cantidad de registros del dataset es: 138047

96724

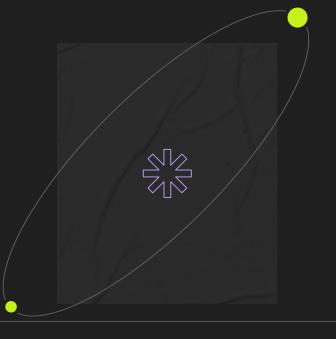
1 41323

Name: legitimate, dtype: int64



04

Implementación de los modelos

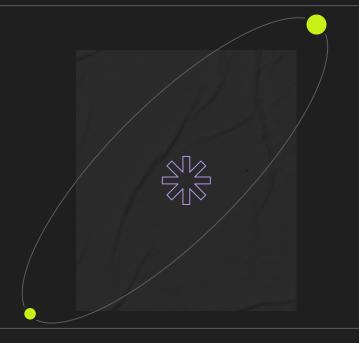


```
# Modelo 1: Regresión Logística
model1 = LogisticRegression()
model1.fit(X_train, y_train)
# Modelo 2: Random Forest
model2 = RandomForestClassifier()
model2.fit(X_train, y_train)
# Modelo 3: Support Vector Machines
model3 = SVC()
model3.fit(X_train, y_train)
```



05

Métricas de evaluación



Regresión Logística

Random Forest

Support Vector Machines

Accuracy: 0.9816486866791745 **Precision:** 0.9623708325209592

Recall: 0.9762658227848101

F1: 0.96926853215513

Confusion matrix: [11807, 193]

[120, 4936]

Accuracy: 0.9949577861163227 **Precision:** 0.9893658920834975

Recall: 0.9936708860759493

F1: 0.9915137162028813

Confusion matrix: [11946, 54]

[32, 5024]

Accuracy: 0.9893878986866792 **Precision:** 0.9782224838140082

Recall: 0.9861550632911392

F1: 0.9821727568206441

Confusion matrix: [11889, 111]

[70, 4986]





Validación Cruzada

Regresión Logística

Random Forest Support Vector Machines

Accuracy: 0.9784353004423192
Precision: 0.9803188575077314
Recall: 0.9739671360741458

F1: 0.9771307024177563

Accuracy: 0.9961519525226235 **Precision:** 0.9945077081580076 **Recall:** 0.9969760250494717 **F1:** 0.995894845996788

Accuracy: 0.9880593527880693 **Precision:** 0.9889209501771783 **Recall:** 0.9858002995045533 **F1:** 0.9873573649750609

